==
CAPÍTULO 4: ANÁLISIS DE RESULTADOS Y DISCUSIÓN
==

En esta sección se evalúa de manera cuantitativa y cualitativa el impacto de la cuantización estática PTQ (Post-Training Quantization) en precisión de 8 bits (INT8) sobre los modelos de red neuronal desarrollados para el Trabajo de Fin de Grado: el modelo base (MLP baseline) y el modelo optimizado mediante destilación de conocimiento (MLP + KD).

Todas las pruebas de inferencia, métricas de latencia, consumo de memoria y caracterización energética se han ejecutado localmente en la plataforma embebida NVIDIA Jetson Orin Nano, utilizando la arquitectura de CPU ARM (aarch64) y el motor de ejecución cuantizada QNNPACK en PyTorch (FX Graph Mode).

4.1. RESUMEN GLOBAL DE MÉTRICAS EXPERIMENTALES

La siguiente tabla resume los resultados obtenidos tras la caracterización de los modelos en sus distintas versiones (punto flotante de 32 bits vs. enteros de 8 bits) y sobre las distintas unidades de procesamiento del kit de desarrollo (CPU vs. GPU):

Modelo	Precisión / Exec	Accuracy	Latencia (ms)	Desviación (ms)	Tamaño Disco	Consumo Medio (W)
MLP baseline	FP32 (GPU CUDA)	100.0%	0.643 ms	± 0.021 ms	16.10 MB	—
	FP32 (CPU ARM)	100.0%	1.848 ms	± 0.381 ms	16.10 MB	—
	INT8 (CPU QNNPACK)	100.0%	1.454 ms	± 0.241 ms	4.08 MB	9.08 W
MLP + KD	FP32 (GPU CUDA)	100.0%	0.649 ms	± 0.097 ms	16.10 MB	—
(T=4, alpha=0.7)	FP32 (CPU ARM)	100.0%	1.836 ms	± 0.211 ms	16.10 MB	—

| | INT8 (CPU QNNPACK) | 100.0% | 1.427 ms | ± 0.032 ms | 4.08 MB | 9.16 W |
+----------+----------+----------+----------+----------+----------+----------+

4.2. DISCUSIÓN TÉCNICA Y ANÁLISIS DE LOS RESULTADOS

---

1. CONSERVACIÓN DE LA EXACTITUD (0.00 pp DE DEGRADACIÓN)

Ambos modelos (MLP baseline y el modelo entrenado con Knowledge Distillation) mantienen una exactitud del 100.0% tras el proceso de cuantización estática. Esto demuestra que la etapa de calibración —utilizada para estimar los rangos dinámicos (mínimos y máximos) de las activaciones mediante la inserción de observadores de PyTorch— calculó de forma precisa la escala (scale) y el punto cero (zero-point). La conversión a enteros de 8 bits no produjo pérdida de información por desbordamiento (overflow) o saturación (clipping).

2. COMPRESIÓN DE ALMACENAMIENTO Y MEMORIA (FACTOR ×3.94)

El tamaño del archivo del modelo almacenado en disco pasó de 16.10 MB a 4.08 MB, lo que supone una reducción exacta del 74.6% (un factor de compresión de 3.94×). Esta reducción es consistente con la teoría (32 bits / 8 bits = 4×) y representa un logro fundamental para el despliegue en sistemas embebidos (Edge AI), ya que:

a) Libera ancho de banda de la memoria RAM unificada LPDDR5 de la Jetson.
b) Minimiza los tiempos de transferencia de I/O al cargar el modelo desde la memoria secundaria a la principal.

3. ACELERACIÓN Y ESTABILIDAD EN CPU ARM (SPEEDUP ×1.29)

Al comparar la ejecución de la red en la CPU de la Jetson (ARM Cortex-A78AE):

- Ganancia de velocidad: La latencia disminuyó de ~1.85 ms a ~1.43 ms, lo que se traduce en una aceleración directa de 1.28× a 1.29×. Esto se logra gracias a que el backend QNNPACK aprovecha las instrucciones vectoriales SIMD/NEON nativas de la arquitectura ARM para operaciones en INT8.
- Mayor determinismo: Destaca la drástica reducción en la variabilidad del tiempo de inferencia del modelo con KD cuantizado (desviación estándar de ±0.032 ms frente a ±0.211 ms en FP32). En aplicaciones de tiempo real (robótica, drones, comunicaciones), este comportamiento determinista es tan crucial como la latencia media.

4. COMPARATIVA CPU (INT8) VS. GPU (FP32)

Aunque la cuantización optimiza notablemente la ejecución en la CPU, la GPU NVIDIA Ampere dedicada mediante CUDA continúa registrando la menor latencia absoluta (0.643 ms en FP32). Esto se explica por la diferencia arquitectónica:

la GPU cuenta con 1024 núcleos CUDA diseñados para la ejecución paralela masiva de multiplicaciones matriciales. En un MLP pequeño, la GPU contrarresta la mayor precisión (32 bits) mediante su superior ancho de banda de memoria y paralelismo, mientras que la cuantización INT8 de PyTorch actual ejecuta su grafo computacional en los núcleos de la CPU (host).

5. CARACTERIZACIÓN ENERGÉTICA
El consumo medio medido mediante los sensores I2C INA3221 de la Jetson se mantuvo estable alrededor de los 9.12 W (9.08 W en baseline y 9.16 W en KD). Esto sitúa la ejecución holgadamente dentro del presupuesto térmico y de potencia configurado en la placa (modo MAXN SUPER de 15W/25W), garantizando la viabilidad de su operación en dispositivos alimentados por batería.

==
CAPÍTULO 5: CONCLUSIONES FINALES Y TRABAJO FUTURO
==

5.1. CONCLUSIONES FINALES

1. VIABILIDAD DE LA CUANTIZACIÓN PTQ EN HARDWARE EMBEBIDO
Se ha demostrado empíricamente que la cuantización estática post-entrenamiento (PTQ) a 8 bits es una técnica sumamente eficiente para redes neuronales en hardware Edge. Proporciona un ahorro de memoria del 74.6% y una aceleración del ~29% en la CPU de la NVIDIA Jetson Orin Nano sin degradar en absoluto la precisión del modelo (0.00 pp).

2. COMPATIBILIDAD CON KNOWLEDGE DISTILLATION (KD)
El modelo entrenado mediante destilación de conocimiento no solo soportó la cuantización a INT8 sin perder precisión, sino que ofreció el tiempo de inferencia más estable y determinista del estudio (1.427 ms ± 0.032 ms). Esto confirma que KD y Cuantización son técnicas complementarias que pueden combinarse secuencialmente.

3. ELECCIÓN DE BACKEND Y ARQUITECTURA DE HARDWARE
El uso del backend QNNPACK fue indispensable para desbloquear el rendimiento de enteros de 8 bits en la CPU ARM (aarch64) de la Jetson. El estudio evidencia que la optimización de software en Edge AI debe adaptarse estrechamente a las capacidades y extensiones de la arquitectura hardware destino.

4. BALANCE ENTRE CPU INT8 Y GPU FP32
Para este tamaño de modelo, la GPU CUDA en FP32 (0.643 ms) sigue siendo más rápida que la CPU en INT8 (1.427 ms). No obstante, la cuantización INT8 en CPU se

presenta como una solución estratégica de alto valor para liberar completamente la GPU para otras tareas concurrentes (procesamiento de vídeo, localización o control).

5.2. TRABAJO FUTURO

1. Exportación y optimización del modelo mediante NVIDIA TensorRT para ejecutar la cuantización INT8 directamente en los Tensor Cores de la GPU CUDA.
2. Exploración de Poda Estructurada (Structured Pruning) sobre las capas lineales para reducir el número real de neuronas y acelerar tanto la ejecución en GPU como en CPU.
3. Evaluación con datasets de mayor complejidad o señales en entornos con ruido variable para analizar el límite de degradación de la cuantización PTQ y comparar su rendimiento con Quantization-Aware Training (QAT).